


1. 变分自编码器的基本思想

变分自编码器（Variational Autoencoder, VAE）与传统自编码器在结构上很相似，但本质上属于不同的机器学习种类。变分自编码器属于曲型的生成式模型，而传统自编码器是一种表示学习方法，其主要目的是特征提取。

1.1 自编码器的不足

一般情况下，传统自编码器缺乏有效的生成能力。以图像数据为例，假设我们已经训练好了一个传统的自编码器，此时潜在空间中存在一些离散的点，每个点对应着训练数据的压缩表示。例如，点A可能对应一张猫的图片的编码，点B对应一张狗的图片，而点C则对应一张鸟的图片。自编码器在重建任务上表现良好，但当我们试图从潜在空间中随机选择一个新的点D进行解码时，很可能会得到毫无意义的噪声图像。这是因为点D从未在训练过程中出现过，解码器对这个区域的映射关系毫无了解。

传统自编码器的潜在空间本质上是稀疏和不连续的，只有少数几个孤立的点具有明确的含义，而大部分区域都是未定义的。这种特性使得传统自编码器更像是一种数据压缩工具，而非真正的生成模型。




1.2 解决问题的思路

这里以一个例子开始，来理解生成问题的一种解决方案。从机器学习的角度来看，绘画的创作毫无疑问属于生成问题。我们可以将画家看作一个生成式模型。以画马为例，一个画家要想学会画马，他首先要看很多的马，然后根据马的特征来画画。如果将画家看作一个普通的自编码器，那么他只会临摹，几乎不可能画出一匹新的马。要想创作，画家必须学会利用一组特征来描述马，例如马四肢的比例、肌肉的分布等等。从概率的角度来看，画家必须掌握这些特征的分布，才能画出新的马来。因为绝大多数特征的组合得到的结果“不像马”。

这个例子中的“特征”可以理解为自编码器中的编码向量，传统自编码器只是把输入数据的信息压缩进去，而并没有学到其取值的概率分布。这就使得对于生成器来说，输入编码向量几乎不可能输出一幅真正的“马”来。

变分自编码器通过引入概率分布的概念，解决了传统自编码器的稀疏性问题。VAE不再将每个数据点映射到潜在空间中的固定位置，而是将其映射到一个概率分布上。这意味着每个训练样本不再对应潜在空间中的一个点，而是对应一个有一定范围的区域。这种设计的巧妙之处在于，它使得整个潜在空间都被概率密度“填满”了。当我们从分布中随机采样一个潜在变量时，这个点几乎总是位于某些训练数据分布的覆盖范围内，因此解码器能够产生有意义的输出。此外，VAE还通过正则化项强制潜在分布接近标准正态分布，这进一步保证了潜在空间的结构性和可采样性。这种设计使得VAE既能准确重建训练数据，又能生成全新的、合理的数据样本，真正实现了生成建模的目标。



1.3 VAE的核心组件

变分自编码器的架构建立在传统自编码器的基础上，但引入了重要的概率性改进。整个系统包含三个相互关联的核心组件。

- **编码器**，其作用不再是简单地将输入数据压缩为固定的编码向量，而是学习将输入数据映射到潜在表示的分布参数上。这意味着对于同一个输入，编码器输出的是描述一个概率分布的参数，而不是确定性的数值。
- **潜在空间**，这是VAE区别与传统自编码最重要的创新之一。与传统自编码器的潜在空间不同，VAE的潜在空间被设计为一个结构良好的概率空间，通常遵循标准正态分布。这种设计使得整个潜在空间都有明确的概率密度，从任何位置采样都能得到有意义的结果。
- **解码器**，它从潜在空间中的采样点重构出数据。由于潜在空间具有良好的概率结构，解码器不仅能重建训练数据，还能从随机采样的潜在变量生成全新的、合理的数据样本。

VAE的关键创新在于编码器输出的是一个概率分布（更准确地说，是一个概率分布的参数），而不是固定的编码向量。这个改变将传统自编码器改变为具有生成建模能力模型。

2. 变分自编码器建模

理解了传统自编码器的局限性后，我们接下来探讨VAE是如何通过引入概率的概念来解决这些问题的。VAE的关键在于将确定性的编码过程转变为概率性的推理过程。

2.1 生成过程：从潜在变量到数据

变分自编码器采用概率的视角来重新理解数据的生成和编码过程。在VAE的框架下，我们将观测到的数据看作是一个由包含两个随机步骤的过程产生的结果。

第一步中，我们从某个简单的先验分布中采样一个潜在变量 $\mathbf{z}$ 。这个先验分布通常选择为标准正态分布 $\mathcal{N}(\mathbf{0}, \mathbf{I})$ ，因为它具有良好的数学性质且易于采样。可以将这个潜在变量理解为数据的"基因"，它包含了生成特定数据所需的关键信息。

第二步中，根据采样得到的潜在变量 $\mathbf{z}$ ，按照某个条件分布 $p_{\theta}(\mathbf{x}|\mathbf{z})$ 来生成实际的观测数据 $\mathbf{x}$ 。这个条件分布由解码器神经网络参数化，它学习如何将抽象的潜在表示转换为具体的数据实例。

用数学语言描述，整合整个过程可表示为：

$$\mathbf{z} \sim p(\mathbf{z}) = \mathcal{N}(\mathbf{0}, \mathbf{I})$$

$$\mathbf{x} \sim p_{\theta}(\mathbf{x}|\mathbf{z})$$

通过这种方式，将复杂数据分布的学习分解为两个相对简单的部分：一个简单的先验分布和一个由神经网络参数化的条件分布。

2.2 推断过程：从数据到潜在变量

在生成模型中，我们不仅关心如何从潜在变量生成数据，还需要解决逆向问题：给定一个观测数据，如何推断出最可能产生它的潜在变量？这就是后验推断问题。

根据贝叶斯定理，后验分布可以表示为：

$$p_{\theta}(\mathbf{z}|\mathbf{x}) = \frac{p_{\theta}(\mathbf{x}|\mathbf{z})p(\mathbf{z})}{p_{\theta}(\mathbf{x})}$$

该式在理论上给出了精确的后验分布，但在建模实践中却无法直接使用。因为分母 $p_{\theta}(\mathbf{x})$ 的计算需要对所有可能的潜在变量进行积分：

$$p_{\theta}(\mathbf{x}) = \int p_{\theta}(\mathbf{x}|\mathbf{z})p(\mathbf{z})d\mathbf{z}$$

这个积分在贝叶斯学习中称为证据、边缘概率或者边际似然，在高维情况下通常是难以计算的。VAE的解决方案是引入一个新的神经网络 $q_{\phi}(\mathbf{z}|\mathbf{x})$ 来近似真实后验分布。这个网络被称为编码器或推断网络，它学习将观测数据映射到潜在变量的近似后验分布上。

2.3 VAE的完整架构

至此，我们得到了VAE的完整概率框架。这个框架包含三个核心的概率分布，它们共同定义了整个模型的行为。

- 编码器 $q_{\phi}(\mathbf{z}|\mathbf{x})$ 扮演着近似后验分布的角色，它将观测数据映射到潜在空间中的概率分布。与传统自编码器不同，VAE的编码器不是简单地输出一个固定的编码向量，而是输出一个分布的参数，当先验分布是正态分布时就是均值和方差。
- 解码器 $p_{\theta}(\mathbf{x}|\mathbf{z})$ 定义了生成分布，它描述了给定潜在变量时观测数据的条件概率。这个分布同样由神经网络参数化，它学习如何将潜在表示转换回数据空间。
- 先验分布 $p(\mathbf{z}) = \mathcal{N}(\mathbf{0}, \mathbf{I})$ 是一个简单的标准正态分布，它为潜在空间提供了基础的概率结构。选择标准正态分布作为先验有多重优势：它易于采样、具有良好的数学性质，且能够确保潜在空间的连续性。

VAE的训练目标是让这三个分布协调工作，使得编码器学会将数据映射到合理的潜在分布，解码器学会从潜在分布生成高质量的数据，同时整个过程保持与先验分布的一致性。这种设计巧妙地平衡了数据重建的准确性和潜在空间的规律性，使得VAE既能作为压缩工具，又能作为生成模型使用。

3. VAE的优化目标

传统自编码器的训练目标非常直观，就是使得重构损失越小越好。作为一个生成式模型，仅使用重构损失，不足以满足VAE的需要。因为VAE不是要生成与训练数据相同的数据，而是要生成与目标“越相越好”的数据。

3.1 证据下界

用概率的语言来描述，所谓的“越相越好”，就是我们要生成的 $\mathbf{x}$ 在现实中观测到的概率越大越好。也就是说，我们要最大化的是 $p_{\theta}(\mathbf{x})$ 。显然，我们无法直接对它进行优化。在贝叶斯学习中，通常会针对它的一个下界进行优化，而这个下界是容易计算的，称为证据下界（Evidence Lower Bound，ELBO）。证据下界是贝叶斯学习或变分方法最重要的精髓之一。

最大化证据（边际似然）等价于最大化其对数：

$$\log p_{\theta}(\mathbf{x}) = \log \int p_{\theta}(\mathbf{x}|\mathbf{z})p(\mathbf{z})d\mathbf{z} = \log \int p_{\theta}(\mathbf{x}, \mathbf{z})d\mathbf{z}$$

为了在式中引入后验分布 $q_{\phi}(\mathbf{z}|\mathbf{x})$ ，我们在积分中乘以并除以这个分布。这种思想在统计学与机器学习中称为重要性采样：

$$\log p_{\theta}(\mathbf{x}) = \log \int q_{\phi}(\mathbf{z}|\mathbf{x}) \frac{p_{\theta}(\mathbf{x}, \mathbf{z})}{q_{\phi}(\mathbf{z}|\mathbf{x})} d\mathbf{z}$$

由于 $q_{\phi}(\mathbf{z}|\mathbf{x})$ 是一个概率密度函数，因此上式中的积分可以看作是对 $\frac{p_{\theta}(\mathbf{x}, \mathbf{z})}{q_{\phi}(\mathbf{z}|\mathbf{x})}$ 在概率 $q_{\phi}(\mathbf{z}|\mathbf{x})$ 下求数学期望：

$$\log p_{\theta}(\mathbf{x}) = \log \mathbb{E}_{q_{\phi}(\mathbf{z}|\mathbf{x})} \left[\frac{p_{\theta}(\mathbf{x}, \mathbf{z})}{q_{\phi}(\mathbf{z}|\mathbf{x})} \right]$$

根据Jensen不等式，对数的期望总是不大于期望的对数：

$$\log \mathbb{E}[X] \geq \mathbb{E}[\log X]$$

可知：

$$\begin{aligned} \log p_{\theta}(\mathbf{x}) &\geq \mathbb{E}_{q_{\phi}(\mathbf{z}|\mathbf{x})} \left[\log \frac{p_{\theta}(\mathbf{x}, \mathbf{z})}{q_{\phi}(\mathbf{z}|\mathbf{x})} \right] \\ &= \mathbb{E}_{q_{\phi}(\mathbf{z}|\mathbf{x})} [\log p_{\theta}(\mathbf{x}, \mathbf{z})] - \mathbb{E}_{q_{\phi}(\mathbf{z}|\mathbf{x})} [\log q_{\phi}(\mathbf{z}|\mathbf{x})] \end{aligned}$$

这就是著名的证据下界（ELBO）。期望值很容易通过采样的方式进行估计（蒙特卡洛方法），因此证据下界将一个难以计算的边际似然转换为了一个可以通过蒙特卡洛采样估计的下界。虽然我们无法直接最大化边际似然，但我们可以最大化这个下界间接地提升边际似然。

3.2 证据下界的理解

为了更好地理解ELBO的含义，我们需要将其分解为两个具有明确物理意义的组成部分。利用联合分布的分解 $p_{\theta}(\mathbf{x}, \mathbf{z}) = p_{\theta}(\mathbf{x}|\mathbf{z})p(\mathbf{z})$ ，可以将ELBO重写为：

$$\text{ELBO} = \mathbb{E}_{q_{\phi}(\mathbf{z}|\mathbf{x})} [\log p_{\theta}(\mathbf{x}|\mathbf{z})] + \mathbb{E}_{q_{\phi}(\mathbf{z}|\mathbf{x})} [\log p(\mathbf{z})] - \mathbb{E}_{q_{\phi}(\mathbf{z}|\mathbf{x})} [\log q_{\phi}(\mathbf{z}|\mathbf{x})]$$

组合后两项，可得到：

$$\text{ELBO} = \underbrace{\mathbb{E}_{q_{\phi}(\mathbf{z}|\mathbf{x})} [\log p_{\theta}(\mathbf{x}|\mathbf{z})]}_{\text{重构项}} - \underbrace{KL(q_{\phi}(\mathbf{z}|\mathbf{x})||p(\mathbf{z}))}_{\text{正则项}}$$

其中，重构项衡量的是解码器的重构质量。它表示在近似后验分布下，解码器准确重建原始数据的期望对数似然。该项鼓励模型学习能够高质量重建输入数据的表示，确保编码-解码过程的有效性。正则项是一个KL散度，它衡量近似后验分布与先验分布之间的差异。这一项的作用是防止编码器学习到过于复杂或不规律的潜在表示。通过最小化这个KL散度，我们强制编码器输出的分布尽可能接近简单的先验分布，这保证了潜在空间的结构性和可采样性。

ELBO体现了VAE在模型复杂度和拟合能力之间找到最佳平衡点的特点。重建项确保了模型的拟合能力。如果没有这一项，模型可能会学到与输入数据无关的随意表示。通过最大化重建似然，我们确保编码器能够提取出对重建任务有用的信息，而解码器能够利用这些信息准确恢复原始数据。正则项则控制了模型的复杂度。如果没有这一项，编码器可能会将每个数据点映射到潜在空间中的一个极小的、孤立的区域，这样虽然能够完美重建训练数据，但无法泛化到新的数据点，更无法用于生成任务。KL正则项通过强制潜在表示接近先验分布，确保了潜在空间的连续性和规律性。在训练过程中，模型会自动在这两个目标之间找到最佳平衡，既保证重建质量，又确保生成能力。这正是VAE能够同时用作压缩工具和生成模型的根本原因。

3.3 优化目标的计算方法

在ELBO中， $p_{\theta}(\mathbf{z}|\mathbf{x})$ 为VAE的解码器， $q_{\phi}(\mathbf{z}|\mathbf{x})$ 为VAE的编码器， $p(\mathbf{z})$ 是我们假设的标准正态先验分布。我们这里关注的是KL散度的计算。当近似后验和先验都是高斯分布时，KL散度存在解析形式。以一维正态分布为例：

$$KL = \int q(z) \log \frac{q(z)}{p(z)} dz = \int \mathcal{N}(z; \mu, \sigma^2) \log \frac{\mathcal{N}(z; \mu, \sigma^2)}{\mathcal{N}(z; 0, 1)} dz$$

将正态分布概率密度函数代入上式，容易求得：

$$KL = \frac{1}{2}(\mu^2 + \sigma^2 - \log \sigma^2 - 1)$$

在高维情况下，如果协方差矩阵是对角矩阵，且先验是标准正态分布，则KL散度是各个维度上的KL散度之和：

$$KL = \frac{1}{2} \sum_{j=1}^k (\mu_j^2 + \sigma_j^2 - \log \sigma_j^2 - 1)$$

4. 重参数化技巧

基于以上分析，我们可以通过最优化证据下界的方式来求解VAE。但是，VAE的计算过程中存在一个不可导的运算：解码器的输入向量 $\mathbf{z}$ 要从由编码器输出确定的正态分布中采样得到。这就使得我们无法通过反向传播计算梯度，进而也不能利用梯度下降求解。**重参数化技巧**（Reparameterization trick）是解决这类问题的一种非常高效非常优雅的方法。

重参数化技巧的核心思想是将采样过程从模型计算过程中“分离”出来，使得其不再出现在梯度传播的路径之上。具体来说，我们不再直接从目标分布采样，而是先从一个简单的标准正态分布采样噪声 $\epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ ，然后通过确定性的概率变换得到目标分布的样本：

$$\mathbf{z} = \boldsymbol{\mu} + \boldsymbol{\sigma} \odot \boldsymbol{\epsilon}$$

容易证明，如果 ϵ 服从标准正态分布，那么 $\boldsymbol{\mu} + \boldsymbol{\sigma} \odot \boldsymbol{\epsilon}$ 服从 $\mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\sigma}^2)$ 分布。这就使得重参数化技巧和直接采样在数学上完全等价。

通过比较直接采样的计算流程和重参数化的计算流程，容易理解为什么重参数化技巧为什么能够解决VAE不可导的问题。在直接采样中，我们得到 $\mathbf{z}$ 的过程如下：

$$\text{编码器} \rightarrow \mu, \sigma \rightarrow \mathcal{N}(\mu, \sigma) \xrightarrow{\text{采样}} \mathbf{z}$$

而在重参数化技巧下：


$$\begin{aligned} & \mathcal{N}(\mathbf{0}, \mathbf{1}) \xrightarrow{\text{采样}} \epsilon \\ \text{编码器} & \rightarrow \mu, \sigma \rightarrow \mu + \sigma \odot \epsilon \rightarrow \mathbf{z} \end{aligned}$$

采样过程位于前向计算路径之外，因此不影响梯度反向传播过程。

从实现角度来看，重参数化技巧还有数值稳定的重要优势。通常，我们令编码器并不直接输出方差，而是其对数值 $\mathbf{v} = \log \sigma^2$ ，在采样时先根据 $\sigma = \exp(\frac{\mathbf{v}}{2})$ 得到方差，再进行重参数化变化。

5. 实例


- vae.py
- MNIST 2 维潜在空间（均值向量）可视化



- 两个图像潜在均值向量之间插件生成



- 潜在空间网格采样生成



6. 小结

变分自编码器 (VAE) 通过引入变分推断和重参数化技巧，为自编码器注入了概率建模的能力，使潜在空间不仅具有压缩性，还具备生成性和结构性。VAE 的训练目标结合了重构误差与 KL 散度正则化，既保证了生成数据的质量，也确保了潜在空间的连续性和可采样性。实践中，VAE 已广泛应用于图像生成、语音建模、自然语言处理以及分子生成等多个领域，成为深度生成模型的重要基石。

变分自编码器相比于其他生成模型具有多个显著优势，这些优势使其在许多实际应用中成为首选的解决方案。

VAE的最大优势在于其结构化的潜在空间。与传统自编码器不同，VAE的潜在空间遵循明确的概率分布，通常是标准正态分布。这种设计带来了多重好处：首先，我们可以轻松地从先验分布中采样来生成新的数据样本，而无需依赖训练数据；其次，潜在空间具有良好的连续性，相邻的点往往对应语义上相似的输出；最后，这种结构化特性支持各种有趣的潜在空间操作，如插值和向量运算。

VAE的另一个重要优势是其坚实的理论基础。整个框架建立在变分推断的严格数学基础上，ELBO提供了明确且可解释的优化目标。这种理论基础不仅有助于理解模型的行为，还为模型的改进和扩展提供了指导。相比之下，许多其他生成模型缺乏如此清晰的理论解释。

尽管VAE具有许多优势，但它也存在一些重要的局限性，了解这些局限性对于正确使用VAE至关重要。

生成结果的模糊性是VAE最明显的问题之一。由于VAE通常使用均方误差作为重建损失，而这种损失函数会导致生成的图像趋向于所有可能输出的平均值，结果往往显得模糊不清。此外，优化证据下界（ELBO）本身以及强大的先验分布约束，也共同导致了生成结果倾向于保守和平滑，从而表现出模糊性。这个问题在图像生成任务中尤为明显，VAE生成的图像通常缺乏清晰的细节和锐利的边缘。研究者们提出了多种解决方案，包括使用更复杂的解码分布、结合对抗训练等方法。

后验崩塌是VAE训练中经常遇到的另一个问题。在某些情况下，KL正则项会促使编码器忽略输入信息，总是输出接近先验分布的编码。这会导致所有输入都被映射到相似的潜在表示，从而失去了编码的意义。 β -VAE、KL退火、free bits等技巧都是为了解决这个问题而提出的。

VAE的表达能力也受到一定限制。高斯分布的假设虽然在数学上便于处理，但可能过于简化了真实数据的复杂分布。对于一些具有复杂多模态分布的数据，简单的高斯假设可能无法充分捕捉其特性。研究者们通过引入更复杂的分布（如normalizing flows）来解决这个问题，但这也增加了模型的复杂性。

参考文献

- 变分自编码器：Auto-Encoding Variational Bayes, 2013.